

30 Challenges NumPy

Parcours d'exercices pratiques pour maîtriser le calcul numérique en Data Science & Intelligence Artificielle

Niveau 1 — Fondamentaux NumPy

Challenge 1 — Analyse d'un tableau de ventes

Objectif : Découvrir la structure fondamentale d'un tableau NumPy.

CONSIGNES

- Créer un tableau NumPy contenant les ventes réalisées par une entreprise sur plusieurs jours.
- Afficher : le type du tableau, sa `shape`, son nombre de dimensions avec `ndim`, son nombre d'éléments avec `size`, son type de données avec `dtype`, la première et la dernière valeur, ainsi que le minimum, le maximum et la moyenne des ventes.

NOTIONS : `np.array()` `ndarray` `shape` `ndim` `size` `dtype` `min()` `max()` `mean()`

Challenge 2 — Génération d'un jeu de données

Objectif : Savoir créer des données numériques avec NumPy.

CONSIGNES

- Créer plusieurs séries représentant : les jours d'une période, des températures, des prix, et des identifiants de produits.
- Utiliser différentes méthodes de génération de tableaux.
- Comparer les tableaux obtenus et afficher leurs caractéristiques.

NOTIONS : `arange()` `linspace()` `zeros()` `ones()` `full()` `dtype`

Challenge 3 — Analyse des notes d'étudiants

Objectif : Manipuler et analyser un tableau de données numériques.

CONSIGNES

- Créer un tableau contenant les notes de plusieurs étudiants dans différentes matières.
- Pour chaque matière : afficher la moyenne, trouver la meilleure et la plus faible note, calculer l'écart entre elles, et identifier les étudiants ayant obtenu une note supérieure à la moyenne.

NOTIONS : `indexation` `axis` `mean()` `min()` `max()` `comparaisons`

Challenge 4 — Analyse d'un dataset multidimensionnel

Objectif : Comprendre les tableaux NumPy 2D.

CONSIGNES

- Créer un tableau représentant plusieurs clients avec : âge, revenu, nombre d'achats, montant dépensé.
- Afficher : les informations d'un client, une colonne complète, plusieurs lignes, les dimensions du dataset, et le nombre total de clients.

NOTIONS : tableaux 2D shape indexation slicing axis

Challenge 5 — Extraction et modification des données

Objectif : Maîtriser l'accès et la modification des éléments d'un tableau.

CONSIGNES

- À partir d'un dataset client : modifier certaines valeurs, remplacer une ligne/colonne, extraire des lignes/colonnes spécifiques, et créer une copie indépendante du dataset.
- Vérifier que la modification d'une copie ne modifie pas le tableau original.

NOTIONS : indexation slicing affectation copy()

🟡 Niveau 2 — Manipulation et analyse

Challenge 6 — Analyse automatique des performances

Objectif : Utiliser les opérations vectorisées de NumPy.

CONSIGNES

- Pour des ventes de commerciaux, calculer automatiquement : le chiffre d'affaires après remise, le CA avec TVA, le nombre de ventes, la vente moyenne, minimale et maximale.
- Effectuer l'ensemble des calculs directement sur les tableaux, sans utiliser de boucle `for`.

NOTIONS : opérations vectorisées opérateurs arithmétiques sum() mean() min() max()

Challenge 7 — Analyse statistique d'un dataset

Objectif : Utiliser NumPy pour effectuer une première analyse statistique.

CONSIGNES

- Créer un dataset contenant les salaires de plusieurs employés.
- Calculer : moyenne, médiane, variance, écart-type, minimum, maximum, ainsi que le 1er et 3ème quartiles.
- Analyser brièvement les résultats obtenus.

NOTIONS : `mean()` `median()` `var()` `std()` `percentile()`

Challenge 8 — Analyse des températures

Objectif : Manipuler des données temporelles simples.

CONSIGNES

- Créer un tableau représentant les températures enregistrées pendant plusieurs jours.
- Déterminer : la température moyenne, les jours les plus chauds/froids, les températures supérieures à la moyenne, l'amplitude thermique et les variations entre jours consécutifs.

NOTIONS : `indexation` `statistiques` `opérations vectorisées` `diff()` ou `slicing`

Challenge 9 — Analyse par dimension avec axis

Objectif : Comprendre réellement le fonctionnement de `axis`.

CONSIGNES

- Créer un tableau représentant les ventes de plusieurs produits sur plusieurs mois.
- Calculer : les ventes totales et moyennes par produit, les ventes totales et moyennes par mois, ainsi que le meilleur produit et le meilleur mois.

NOTIONS : `axis=0` `axis=1` `sum()` `mean()` `argmax()`

Challenge 10 — Filtrer un dataset avec des conditions

Objectif : Sélectionner des données selon plusieurs critères.

CONSIGNES

- À partir d'un dataset (âge, salaire, ancienneté, dépenses), identifier : les clients > 30 ans, ceux au-dessus d'un salaire donné, respectant plusieurs conditions simultanées ou non.
- Compter le nombre de clients correspondant à chaque critère.

NOTIONS : `masques booléens` `&` `|` `~` `comparaisons`

Niveau 3 — Nettoyage et préparation des données

Challenge 11 — Détection des valeurs anormales

Objectif : Identifier des valeurs potentiellement problématiques dans un dataset.

CONSIGNES

- Créer un tableau de mesures de capteurs comportant des valeurs anormales (extrêmes).
- Identifier : les valeurs normales et suspectes, leur position dans le tableau, leur nombre, et les valeurs hors des seuils définis.

NOTIONS : `masques` `booléens` `where()` `argwhere()` `statistiques`

Challenge 12 — Nettoyage d'un dataset avec valeurs manquantes

Objectif : Découvrir la gestion des valeurs `NaN`.

CONSIGNES

- Créer un dataset contenant des valeurs manquantes (`NaN`).
- Identifier leurs positions, leur nombre, les lignes/colonnes concernées, puis remplacer ces valeurs manquantes par une valeur calculée (ex: moyenne).

NOTIONS : `np.nan` `isnan()` `isfinite()` `nanmean()`

Challenge 13 — Nettoyage et validation des données

Objectif : Construire une étape complète de préparation des données.

CONSIGNES

- Détecter les valeurs invalides dans un dataset (valeurs négatives, trop élevées, ou manquantes).
- Produire une version nettoyée et afficher un bilan avant/après (nombre d'invalides, corrigées, données finales).

NOTIONS : `masques` `where()` `isnan()` `conditions` `statistiques`

Challenge 14 — Trier et analyser un dataset

Objectif : Savoir classer et retrouver les positions des données.

CONSIGNES

- À partir de scores d'utilisateurs : trier dans l'ordre croissant et décroissant, retrouver les positions correspondantes, identifier les 3 meilleurs/pires scores et rechercher les valeurs uniques.

NOTIONS : `sort()` `argsort()` `argmax()` `argmin()` `unique()`

Challenge 15 — Étude complète d'un dataset

Objectif : Combiner plusieurs notions NumPy dans une analyse.

CONSIGNES

- Analyse complète de performances d'étudiants : dimensions, moyennes par matière/étudiant, min/max, étudiants au-dessus de la moyenne, classement, détection d'anomalies et statistiques générales.

NOTIONS : `shape` `axis` `statistiques` `masques` `tri` `argsort()` `unique()`

Niveau 4 — Transformation et opérations avancées

Challenge 16 — Restructurer un dataset

Objectif : Comprendre comment modifier la structure d'un tableau.

CONSIGNES

- Transformer un tableau de plusieurs centaines de valeurs en vecteur, matrice, puis tableau 3D.
- Vérifier à chaque étape `shape` , `ndim` , `size` et comparer `flatten()` et `ravel()` .

NOTIONS : `reshape()` `flatten()` `ravel()` `shape` `ndim`

Challenge 17 — Construire un dataset multi-sources

Objectif : Combiner plusieurs tableaux NumPy.

CONSIGNES

- Construire un dataset final en ajoutant des lignes et des colonnes provenant de sources distinctes.
- Concaténer les tableaux en vérifiant rigoureusement la compatibilité des dimensions.

NOTIONS : `concatenate()` `vstack()` `hstack()` `stack()`

Challenge 18 — Génération de données aléatoires

Objectif : Utiliser NumPy pour créer des données artificielles.

CONSIGNES

- Simuler un dataset client (âge, revenu, achats, score) en utilisant différentes lois de distribution aléatoire.
- Fixer une graine aléatoire pour la reproductibilité et analyser les données générées.

NOTIONS : `np.random` `seed()` `rand()` `randint()` `normal()` `uniform()`

Challenge 19 — Transformation d'un dataset

Objectif : Transformer efficacement les données numériques.

CONSIGNES

- Convertir des unités, appliquer des coefficients, calculer des ratios, créer de nouvelles variables et transposer le dataset sans aucune boucle.

NOTIONS : `vectorisation` `transpose()` `opérations matricielles` `axis`

Challenge 20 — Normalisation des données

Objectif : Préparer des données numériques pour un modèle de ML.

CONSIGNES

- À partir de variables à échelles très différentes (âge, salaire, dépenses), calculer : une normalisation Min-Max et une standardisation (Z-score).
- Comparer les distributions avant et après transformation.

NOTIONS : `vectorisation` `mean()` `std()` `broadcasting` `normalisation` `standardisation`

● Niveau 5 — NumPy pour la Data Science

Challenge 21 — Comprendre le Broadcasting

Objectif : Effectuer des calculs entre tableaux de dimensions différentes.

CONSIGNES

- Appliquer automatiquement des coefficients selon les colonnes et des corrections selon les lignes sans boucle.
- Expliquer le fonctionnement sous-jacent du mécanisme de broadcasting NumPy.

NOTIONS : `broadcasting` `shape` `vectorisation`

Challenge 22 — Calculer des distances entre données

Objectif : Utiliser NumPy pour comparer des observations numériques.

CONSIGNES

- Calculer la distance euclidienne entre un client de référence et tous les autres clients d'un dataset.
- Identifier le client le plus proche, le plus éloigné et afficher le classement complet des distances.

NOTIONS : `vecteurs` `opérations vectorisées` `sqrt()` `sum()` `argmin()` `argmax()`

Challenge 23 — Similarité entre vecteurs

Objectif : Découvrir la similarité cosinus entre représentations numériques.

CONSIGNES

- Créer des vecteurs de caractéristiques et calculer leur similarité basée sur le produit scalaire et leurs normes.
- Extraire les éléments présentant le plus haut degré de similarité.

NOTIONS : produit scalaire dot() norm() sqrt() vectorisation

Challenge 24 — Analyse matricielle

Objectif : Introduire les opérations matricielles fondamentales en Data Science.

CONSIGNES

- Réaliser : transposition, produit matriciel, produit d'Hadamard (élément par élément), calcul de diagonale/trace et résolution d'un système linéaire.

NOTIONS : matrices transpose() @ dot() diag() trace() np.linalg

Challenge 25 — Optimiser un traitement avec la vectorisation

Objectif : Comprendre le gain de performance de NumPy par rapport au Python pur.

CONSIGNES

- Implémenter une même transformation lourde avec une boucle `for` Python puis avec NumPy vectorisé.
- Mesurer le temps d'exécution des deux méthodes et analyser les raisons de l'écart de performance.

NOTIONS : vectorisation timeit / time opérations NumPy performance

● Niveau 6 — Préparation au Machine Learning et à l'IA

Challenge 26 — Préparer X et y pour un modèle

Objectif : Structurer les données au format standard du Machine Learning.

CONSIGNES

- Séparer un dataset complet en une matrice de variables explicatives `x` et un vecteur cible `y`.
- Vérifier la cohérence des dimensions, du nombre d'observations et de caractéristiques.

NOTIONS : slicing shape matrices vecteurs x / y

Challenge 27 — Séparer un dataset en entraînement et test

Objectif : Effectuer un split Train/Test reproductible.

CONSIGNES

- Diviser un dataset de manière aléatoire mais reproductible en un ensemble d'entraînement et un ensemble de test.
- S'assurer de la conservation de l'intégralité des données et de la justesse des ratios.

NOTIONS : `random` `slicing` `permutation` `shuffle()` `shape`

Challenge 28 — Fonction de préparation de données

Objectif : Encapsuler la logique de preprocessing dans une fonction réutilisable.

CONSIGNES

- Créer une fonction qui prend en entrée un dataset brut, impute les valeurs manquantes, corrige les valeurs invalides et normalise les variables.

NOTIONS : `fonctions NumPy` `isnan()` `statistiques` `masques` `broadcasting`

Challenge 29 — Mini pipeline de préparation ML

Objectif : Combiner les compétences de preprocessing dans un pipeline structuré.

CONSIGNES

- Construire un pipeline complet modularisé en fonctions : exploration, détection NaN/anomalies, nettoyage, normalisation, séparation `x/y` et train/test split.

NOTIONS : `ndarray` `statistiques` `masques` `NaN` `vectorisation` `pipeline`



Niveau 7 — Projet final NumPy

Challenge 30 — Projet final : Analyse & Préparation d'un dataset IA

Objectif : Mettre en pratique l'ensemble du parcours dans un projet complet de Data Science.

CONSIGNES

- Développer un programme NumPy complet et modulaire réalisant : chargement, exploration, statistiques, filtrage, détection/imputation NaN, nettoyage d'anomalies, transformations, normalisation, calculs de distances/similarités, extraction de `x/y` et split Train/Test.
- Rédiger un bilan synthétique : transformations effectuées, difficultés rencontrées et rôle clé de NumPy avant Pandas et le Machine Learning.

NOTIONS : Ensemble des compétences NumPy (Niveaux 1 à 6)